Отчёт по учебной практике

Завгороднего Александра

19 июля 2017

Тема: "Анализ наиболее предпочтительных для просмотра кинопремьер по параметрам на сайте imdb.com"

Ход работы

Первая часть работы посвящена созданию таблицы FAMOUSES с полями имя, место в общемировом рейтинге и баллы для подсчёта коэффициента. Для этого обращаемся к странице "Самые популярные мужчины и женщины". Люди из этого списка являются режиссёрами или актёрами. Извлекаем необходимые данные и создаём таблицу.

```
library(XML)
library(RCurl)
```

```
## Loading required package: bitops
```

```
library(bitops)
FAMOUSES = data.frame()
j<-1
options(max.print=9999999)
for (i in 1:50)
{
    strj <- toString(j)
    page<-paste("http://www.imdb.com/search/name?gender=male,female&ref_=nv_tp_cel_1&start=",strj)

    str<-page
    print(str)
    page<-readLines(str)</pre>
```

```
page<-enc2native(page)</pre>
page <- iconv(page, from = "UTF-8", to = "CP1251")</pre>
numbers = grep('',page)
name = page[numbers+1]
name <- sub('.*/\">','',name)
name <- sub('</a>','',name)
numbers <- grep('<td class="number">',page)
number = page[numbers]
number <- sub('.*\">','', number)
number <- sub('.<.*','',number)</pre>
pointcounter = 0
for (k in 1:length(name))
  num<-as.integer(number[k])</pre>
  if (num<2000)
    pointcounter <- 1</pre>
  if (num<1000)
    pointcounter <- 2</pre>
  if (num<750)
    pointcounter <- 3</pre>
  if (num<500)
    pointcounter <- 4
  if (num<250)
    pointcounter <- 5</pre>
  FAMOUSES <- rbind(data.frame(name[k], num, pointcounter),FAMOUSES)</pre>
```

```
j = j + 50
}
print(FAMOUSES)
```

Второй шаг - извлечение данных для основной таблицы PREMIERES, в которой будут поля: название фильма, режиссёр, актёры, возрастное ограничение, рейтинг ожиданий, популярность и дополнительный рейтинг.

```
library(XML)
library(RCurl)
library(bitops)
PREMIERES = data.frame()
page = readLines("http://www.imdb.com/movies-coming-soon/")
page <- enc2native(page)</pre>
numbers = grep('<a href="/title',page)</pre>
href = page[numbers]
doublicate <- FALSE</pre>
i=1
#получение фильмов со второй строки
numbers = grep('<a href="/movies-coming-soon/.*ref =cs dt nx\"',page)</pre>
otherpage = page[numbers]
secondpage<-otherpage[1]</pre>
secondpage<-sub('.*href=\"','http://www.imdb.com',secondpage)</pre>
secondpage<-sub('dt nx\"','dt nx',secondpage)</pre>
print(secondpage)
secondpage = readLines(secondpage)
secondpage <- enc2native(secondpage)</pre>
numbers = grep('<a href="/title', secondpage)</pre>
href2 = secondpage[numbers]
#объединение двух страниц
hrefs = character()
for (i in 1:length(href))
```

```
hrefs[j] <- href[i]</pre>
 j = j + 1
for (i in 1:length(href2))
 hrefs[j] <- href2[i]</pre>
 j = j + 1
j=1
for (i in 1:length(hrefs))
  if (doublicate == FALSE)
    str<-hrefs[i]
    str<- sub('.*title','http://www.imdb.com/title', str)</pre>
    str<- sub('/?ref_.*.','', str)
    str<-substr(str,1,nchar(str)-1)</pre>
    hrefs[i]<-str
    doublicate <- TRUE
    page <- readLines(hrefs[i])</pre>
    page <- enc2native(page)</pre>
    page <- iconv(page, from = "UTF-8", to = "CP1251")</pre>
    #Получение имени
    numbers = grep('<h1 itemprop="name"',page)</pre>
    name = page[numbers]
    name <-sub('.*=\"\">','',name)
    name <-sub('&nbsp.*','',name)</pre>
    print(paste("Название фильма", j, name))
    #Получение рейтинга
    numbers = grep('span itemprop="ratingValue',page)
    rating of expectations = page[numbers]
    rating_of_expectations <-sub('.*ratingValue\">','', rating_of_expectations)
    rating of expectations <-sub('</span>.*','',rating of expectations)
```

```
print(paste("Рейтинг", j, rating_of_expectations))
#Получение режиссера
numbers = grep('span itemprop="director"',page)
director = page[numbers + 2][1]
director <-sub('.*itemprop=\"name\">','',director)
director <-sub('</span>.*','',director)
print(paste("Pexuccep", j, director))
#Получение актеров
numbers = grep('
#print(page[numbers + 2])
actors <- sub('.*itemprop=\"name\">','',page[numbers + 2])
actors <- sub('</span>.*','',actors)
actor1 <- actors[1]</pre>
actor2 <- actors[2]</pre>
actor3 <- actors[3]</pre>
actor4 <- actors[4]</pre>
print(paste("Aktep1", j, actor1))
print(paste("Aktep2", j, actor2))
print(paste("Aktep3", j, actor3))
print(paste("Aktep4", j, actor4))
actor1 <- ifelse(is.na(actor1), "noactor", actor1)</pre>
actor2 <- ifelse(is.na(actor2), "noactor", actor2)</pre>
actor3 <- ifelse(is.na(actor3), "noactor", actor3)</pre>
actor4 <- ifelse(is.na(actor4), "noactor", actor4)</pre>
#возраст
numbers = grep('itemprop="contentRating"',page)
age = page[numbers][1]
age <-sub('.*\">','',age)
print(paste("Возрастное ограничение", j, age))
agenum <-0
age <- ifelse(is.na(age), "G", age)</pre>
```

```
if (age=="PG")
 agenum <-6
if (age=="PG-13")
  agenum <-12
if (age=="R")
  agenum <-16
if (age=="18+")
  agenum <-18
print(agenum)
#pop
numbers = grep('itemprop="ratingCount"', page)
popularity <- page[numbers]</pre>
popularity <-sub('.*ratingCount\">','',popularity)
popularity <-sub('</span>.*','',popularity)
print(paste("∏oπ", popularity))
#оценка Metacritic
numbers = grep('class="metacriticScore', page)
metacritic = page[numbers + 1]
metacritic <-sub('<span>','',metacritic)
metacritic <-sub('</span>','',metacritic)
print(paste("Оценка Metacritic", j, metacritic))
if (length(metacritic)==0)
  metacritic = "0"
if (length(popularity)==0)
```

```
popularity = "0"
}
if (length(rating_of_expectations) == 0)
{
    rating_of_expectations = "0"
}

PREMIERES <- rbind(data.frame(Name=name,Director=director,Role1=actor1,Role2=actor2,Role3=actor3,Role4=actor4,Age=agenum,Rating_of_expectations=rating_of_expectations,Popularity=popularity,Metacritic=metacritic),PREMIERES)

j=j+1
}
else
{
    doublicate <- FALSE
}
print(PREMIERES)</pre>
```

В приведённом выше участке кода строчка:

```
PREMIERES <- rbind(data.frame(Name=name,Director=director,Role1=actor1,Role2=actor2,Role3=actor3,Role4=actor4,Age =agenum,Rating_of_expectations=rating_of_expectations,Popularity=popularity,Metacritic=metacritic),PREMIERES)
```

отвечает за создание таблицы PREMIERES. Далее идёт анализ фильмов на основе двух таблиц FAMOUSES и PREMIERES. Подсчитывается коэффициент для каждого фильма.

```
library(knitr)
# c(...) - concatnation
coefficient <- c(1:nrow(PREMIERES))
# count k
# nrow - number of rows
for(i in 1:nrow(PREMIERES))
{
    k <- 0
    if (PREMIERES$Age[i] == 18)</pre>
```

```
k < -k - 4
  director <- toString(PREMIERES$Director[i])</pre>
 actor1 <- toString(PREMIERES$Role1[i])</pre>
 actor2 <- toString(PREMIERES$Role2[i])</pre>
 actor3 <- toString(PREMIERES$Role3[i])</pre>
  actor4 <- toString(PREMIERES$Role4[i])</pre>
  name <- toString(PREMIERES$Name[i])</pre>
 for(j in 1:nrow(FAMOUSES))
    famous name<-toString(FAMOUSES$name.k.[j])</pre>
    # adding points for director and roles
    if(director == famous name || actor1 == famous name || actor2 == famous name || actor3 == famous name || actor
r4 == famous name)
      k <- k + as.integer(FAMOUSES$pointcounter[j])</pre>
      point<-FAMOUSES$pointcounter[j]</pre>
      print(point)
 # adding points for rating of expectations
 k <- k + as.numeric(toString(PREMIERES$Rating of expectations[i]))</pre>
 pop<-PREMIERES$Popularity[i]</pre>
 pop <-sub(',',',',',',pop)
 # adding points for popularity
 k < -k + as.numeric(pop) / 100
 # adding points for metacritic
 k <- k + as.numeric(toString(PREMIERES$Metacritic[i])) / 10</pre>
  coefficient[i] <- k</pre>
```

Последний этап - добавление столбца с коэффициентами в таблицу, сортировка всей таблицы по добавленному столбцу.

```
# adding column coefficient to table PREMIERES
PREMIERES <- cbind(PREMIERES, coefficient)</pre>
```

print(PREMIERES)

```
PREMIERES <- PREMIERES[order(PREMIERES$coefficient, decreasing = TRUE),]
print(PREMIERES)</pre>
```

```
##
                                         Name
                                                           Director
## 15
                                Ветреная река
                                                    Taylor Sheridan
## 24
                          Взрывная блондинка
                                                       David Leitch
                                                        Matt Spicer
## 11
                            Ingrid Goes West
## 4
                                 Tulip Fever
                                                    Justin Chadwick
                        Проклятие Аннабель 2
                                                  David F. Sandberg
## 14
## 19
                                                      Nikolaj Arcel
                                Темная башня
                                   Sage femme
## 20
                                                     Martin Provost
## 23 An Inconvenient Sequel: Truth to Power
                                                        Bonni Cohen
## 8
                      The Hitman's Bodyquard
                                                     Patrick Hughes
## 7
                                                      Geremy Jasper
                                  Patti Cake$
                                                      Amanda Lipitz
## 16
                                         Step
                           The Trip to Spain
## 9
                                              Michael Winterbottom
## 3
                                   Beach Rats
                                                      Eliza Hittman
## 22
                                      Menashe
                                                 Joshua Z Weinstein
## 13
                            The Glass Castle Destin Daniel Cretton
## 21
                               Иллюзия любви
                                                      Nicole Garcia
## 12
             The Nut Job 2: Nutty by Nature
                                                        Cal Brunker
## 10
             The Only Living Boy in New York
                                                          Marc Webb
## 1
                                         Gook
                                                        Justin Chon
## 2
                                         Gook
                                                        Justin Chon
## 5
                                     Polaroid
                                                      Lars Klevberg
                                Midnight Sun
## 17
                                                        Scott Speer
## 18
                                      Detroit
                                                    Kathryn Bigelow
## 25
                             The Emoji Movie
                                                       Tony Leondis
## 6
                                   All Saints
                                                        Steve Gomer
                                           Role2
                   Role1
                                                               Role3
##
## 15
         Elizabeth Olsen
                                    Jon Bernthal
                                                       Jeremy Renner
## 24
          Sofia Boutella
                                 Charlize Theron
                                                        James McAvov
```

	11	Aubrey Plaza		Elizabeth Olsen	0 ' Sł	nea Jackson J	
	4	Cara Delevingne		Alicia Vikander		Dane DeHa	
		Alicia Vela-Bailey		Miranda Otto		tephanie Sigm	
	19	Katheryn Winnick				new McConaugh	-
	20	Catherine Deneuve		Catherine Frot		Olivier Gourm	
## ##	23	Al Gore		Barack Obama		Donald J. Tru	•
		Gary Oldman		Ryan Reynolds		nuel L. Jacks	
	7	Danielle Macdonald		Bridget Everett	21001		
	16	Paula Dofat		Cori Grainger		Tayla Solom	
##		Steve Coogan		Rob Brydon		Marta Barr	
##		Harris Dickinson		Madeline Weinstein		Kate Hod	•
	22 13	Menashe Lustig Brie Larson		Yoel Falkowitz	1	noact	
	21	Marion Cotillard		Naomi Watts Louis Garrel		Voody Harrels Alex Brendemu	
	12	Will Arnett		Katherine Heigl	ŀ	Maya Rudol	
	10	Kate Beckinsale		Jeff Bridges		Pierce Brosn	•
	1	Simone Baker		Justin Chon	C	rtiss Cook J	
## ##		Simone Baker		Justin Chon		urtiss Cook J urtiss Cook J	
## ##		Kathryn Prescott		Katie Stevens		adelaine Pets	
	5 17	•	Da+ı	rick Schwarzenegger	110	Rob Rigg	
	18	John Boyega	rati	Will Poulter		Algee Smi	
	25	James Corden		Maya Rudolph		Steven Wrig	
##		Cara Buono		John Corbett		Barry Corb	
##	Ü		Δαε	Rating_of_expectat:	ions F	-	
	15	Martin Sensmeier	16	Nating_or_expectati	7.5	693	73
	24	Bill Skarsgard	16		7.3	1,353	68
	11	Wyatt Russell	16		7.0	226	65
##		Christoph Waltz	16		7.2	203	0
	14	Talitha Bateman	16		8.0	517	71
##	19	Jackie Earle Haley	0		0	0	0
##	20	Quentin Dolmaire	0		7.2	453	72
##	23	noactor	0		5.0	715	66
##	8	Salma Hayek	16		0	Θ	0
##		Mamoudou Athie	16		6.1	467	71
##	16	noactor	6		7.2	96	90
##	9	Claire Keelan	0		7.5	259	70
##	3	Neal Huff	16		6.8	129	79

```
## 22
                           6
                                                  6.3
                                                             123
                                                                          82
                 noactor
## 13
             Sarah Snook 12
                                                    0
                                                               0
                                                                           0
## 21
          Brigitte Rouan
                                                  6.7
                                                           1,951
                                                                          44
## 12
             Jackie Chan
                            6
                                                    0
                                                                0
                                                                           0
              Debi Mazar
                           16
                                                                           0
## 10
                                                    0
                                                               0
## 1
                David So
                            0
                                                  8.0
                                                             112
                                                                           0
                David So
## 2
                            0
                                                  8.0
                                                             112
                                                                           0
## 5
            Javier Botet
                            0
                                                    0
                                                               0
                                                                           0
## 17
          Quinn Shephard
                                                    0
                                                               0
                                                                           0
## 18
          Jacob Latimore 16
                                                    0
                                                                           0
                                                                0
## 25
       Jennifer Coolidge
                            6
                                                    0
                                                                0
                                                                           0
## 6
             David Keith
                           6
                                                    0
                                                                0
                                                                           0
##
      coefficient
## 15
         35.73000
## 24
         33.11353
## 11
         30.76000
## 4
         27.23000
         24.27000
## 14
## 19
         20.00000
## 20
         18.93000
## 23
         18.75000
## 8
         18.00000
## 7
         17.87000
## 16
         17.16000
## 9
         17.09000
## 3
         15.99000
## 22
         15.73000
## 13
         15.00000
## 21
         11.11951
## 12
         11.00000
## 10
         10.00000
## 1
          9.12000
## 2
          9.12000
          9.00000
## 5
## 17
          5.00000
## 18
          3.00000
```

25 2.00000 ## 6 1.00000